

Classificação automática de estágios de sono a partir de sinais de EEG single-channel, usando extração de características e combinação de classificadores. Dataset: ISRUC-Sleep Cohort III

Gabriel Farias Marcondes

Universidade Tecnológica Federal do Paraná (UTFPR)
Campo Mourão – PR – Brazil

Departamento Acadêmico de Computação (DACOM)

`gabmar.2003@alunos.utfpr.edu.br`

1. Introdução

O sono ocupa cerca de um terço da vida cotidiana humana e é essencial para a saúde física e cognitiva. A avaliação clínica do sono é feita pela polissonografia (PSG), um exame que registra simultaneamente sinais de eletroencefalograma (EEG), eletrooculograma (EOG) e eletromiograma (EMG) ao longo de uma noite inteira. A partir desse registro, o exame é dividido ao longo de uma noite inteira. A partir deste registro, o exame é dividido em épocas de 30 segundos, e a cada época é classificada em um estágio do sono: Wake, N1, N2, N3, REM. Seguindo o padrão da *American Academy of Sleep Medicine* (AASM).

Atualmente, essa classificação é feita manualmente por especialistas, o que torna o processo caro, demorado e sujeito a variabilidade entre avaliadores. Por isso, há um interesse em automatizar essa tarefa com técnicas de aprendizado de máquina.

Esse trabalho avalia um pipeline de classificação automática de estágios de sono a partir de um único canal de EEG, utilizando o dataset ISRUC-Sleep III. O fluxo cobre a segmentação dos sinais em épocas, a extração de características nos domínios do tempo e da frequência, a classificação com cinco algoritmos distintos e a combinação desses classificadores por votação majoritária. Toda avaliação é feita sob um protocolo de validação por sujeito, que evita o vazamento de informação entre treino e teste. Os resultados mostram que classificadores individuais bem ajustados alcançam desempenho competitivo, e que a combinação simples por votação não necessariamente supera o melhor classificador isolado.

2. Materiais e Métodos

2.1 Dataset

O dataset ISRUC-Sleep III, contém registros polissonográficos (PSG) de 10 sujeitos saudáveis, gravando toda a noite de sono de cada um, contendo arquivos .rec sendo os sinais fisiológicos brutos de Eletroencefalograma (EEG), Eletrooculograma (EOG), Eletromiograma (EMG) com frequência de amostragem de 200 Hz. Dois arquivos de texto por época do sujeito, que são as anotações de dois especialistas, seguindo a codificação: 0=Wake, 1=N1, 2=N2, 3=N3, 5=REM. O valor 4 não existe por conta do padrão AASM que funde o S3+S4 no N3. Logo o 5 fica para o REM por herança da numeração antiga de Rechtschaffen & Kales.

O canal utilizado é o C3-A2 (EEG central esquerdo referenciado à mastoide direita), que é o canal padrão para análise de sono por capturar bem a atividade de fuso (N2) e delta (N3).

2.2 Distribuição de Classes

Após processar os 10 sujeitos, o dataset resultante tem 8.889 épocas:

Estágio	Label	Épocas	Proporção
Wake	0	1.817	20,4%
N1	1	1.248	14,0%
N2	2	2.678	30,1%
N3	3	2.035	22,9%
REM	4	1.111	12,5%

Por que N2 é tão evidente? Em um adulto saudável, o sono N2 compõe 45-55% da noite. O N1 e REM são estágios de transição e curtos. Essa assimetria natural das classes é um problema para os classificadores, a métrica de Macro-F1 (que pondera as classes igualmente) é mais correta que acurácia bruta nesses casos.

Observação: A biblioteca *Scikit-Learn* exige que o mapeamento dos rótulos sejam contínuos, por isso, e também no código, foi remapeado para seguir {0, 1, 2, 3, 4}. O 5 (REM original) vira 4.

2.3 Pré-Processamento

Antes da extração de características, o sinal contínuo de cada sujeito foi segmentado em épocas de 30 segundos, seguindo o padrão AASM. Como a frequência de amostragem do ISRUC-Sleep III é de 200Hz, cada época corresponde a 6.000 (200Hz x 30s).

Para cada sujeito, extraiu-se o canal C3-A2 e dividiu-se o sinal em épocas consecutivas e não sobrepostas. Cada época foi pareada com o rótulo correspondente fornecido nas anotações do especialista. O número de épocas do sinal foi comparado ao número de anotações para garantir o alinhamento entre os dois; eventuais amostras finais que não completassem uma época inteira foram descartadas.

Após processar os 10 sujeitos, obteve-se um conjunto de 8.889 épocas, cada uma representada por 6.000 amostras brutas e associada a um rótulo de estágio. Registrou-se também, para cada época, o identificador do sujeito de origem, uma informação essencial para o protocolo de validação por sujeito descrito adiante.

2.4 Extração de Características

Para as Features de Domínio de Tempo, foi utilizado os parâmetros de Hjorth (atividade, mobilidade e complexidade) que servem como descritores por capturarem amplitude, frequência média e regularidade com baixo custo computacional. A atividade corresponde à variância do sinal, refletindo sua potência. A mobilidade e a complexidade são obtidas a partir das derivadas do sinal, aproximadas por diferenças discretas sucessivas, uma vez que a derivada amplifica as componentes de alta frequência. A variância da primeira derivada estima a frequência média (mobilidade), enquanto a relação envolvendo a segunda derivada estima a variação dessa frequência (complexidade).

Além dos parâmetros de Hjorth, foram extraídas características estatísticas básicas de cada época no domínio do tempo: média, desvio padrão, variância, assimetria (skewness), curtose (kurtosis) e taxa de cruzamento por zero (zero-crossing rate). A taxa de cruzamento por zero conta quantas vezes o sinal muda de sinal ao longo da época, funcionando como um indicador simples da frequência dominante: sinais mais rápidos cruzam o zero com mais frequência.

No total, cada época foi representada por 15 características, 9 domínios do tempo (as estatísticas básicas, os três parâmetros de Hjorth e a taxa de cruzamento por zero) e 6 no domínio da frequência (as potências relativas das cinco bandas e o SEF95).

Para as Features de Domínio de Frequência, foram extraídas da densidade espectral de potência (PSD), estimada pelo método Welch. A PSD descreve como a energia do sinal se distribui ao longo das frequências, principal informação para o estagiamento do sono, uma vez que os estágios são caracterizados por ritmos espectrais específicos (por exemplo, ondas delta no N3 e fusos na banda sigma no N2). O método Welch foi escolhido por produzir uma estimativa mais estável que o periodograma simples: a época é dividida em segmentos sobrepostos, calcula-se a FFT (*Fast Fourier Transform*) de cada segmento, e os periodogramas resultantes são promediano, reduzindo a variância da estimativa. A partir do PSD, calcula-se a potência relativa em cada banda de frequência (delta, theta, alpha, sigma e beta), normalizada pela potência total para permitir a comparação entre sujeitos com diferentes amplitudes de sinal, além

da frequência de borda espectral (SEF95, onde, em uma época, resume 95% do sinal da banda em um número para ajudar o classificador a distinguir se o sinal é baixo ou lento).

2.5 Classificadores

Foi avaliado 5 classificadores usando *cross-validation* com *leave-one-subject-out* (cada fold testa em um sujeito inteiro). Isso garante que os 10 sujeitos use um sujeito inteiro como teste. Isso é essencial para dados EEG pois como foi gravado uma noite inteira dos sujeitos, misturar épocas de uma gravação de treino e teste, pode inflar a acurácia.

- **k-Nearest Neighbors:** Classifica cada época pela maioria dos **5** vizinhos mais próximos no espaço de features (distância euclidiana). Não aprende um modelo explícito mas guarda todos os exemplos de treino.
- **Decision Tree:** Aprende uma hierarquia de regras sobre as features. Exemplo: *if rel_power_delta > 0.4 → N3*. Propenso a overfitting (cresce até separar perfeitamente do treino).
- **Support Vector Machine com kernel RBF:** Encontra o hiperplano de margem máxima que separa as classes. O kernel RBF (Radial Basis Function) projeta implicitamente as features em um espaço de alta dimensão onde as classes são linearmente separáveis. $C=1.0$ é o parâmetro de regularização: valores menores aumentam a margem mas permitem mais erros de treino.
- **Rede Neural MLP:** Aprende representações das features. 500 é o número máximo de épocas de treinamento (backpropagation).
- **Random Forest:** Um ensemble de 100 árvores de decisão, cada uma treinada em um subconjunto aleatório de amostras e com seleção aleatória de features em cada divisão. A predição final é a votação majoritária entre as 100 árvores. Robusto ao overfitting e o único ensemble nativo entre os 5 classificadores individuais.

2.6 Protocolo de Validação

A avaliação foi feita por *cross-validation* com separação por sujeito (*subject wise*), utilizando o método GroupKFold com 10 partições. Como o dataset contém exatamente 10 sujeitos, cada partição corresponde a um sujeito inteiro usado como teste, enquanto os nove restantes forma o treino, uma configuração equivalente ao protocolo *leave-one-subject-out*.

Essa escolha é essencial para dados EEG. Como cada gravação corresponde a uma noite inteira de um mesmo sujeito, as épocas de um indivíduo são temporariamente correlacionadas e compartilham características individuais. Se as épocas do mesmo

sujeito aparecessem simultaneamente no treino e no teste, o modelo poderia decorar o sujeito em vez de aprender a distinguir os estágios, inflando o desempenho. A separação por sujeito elimina esse vazamento.

Um segundo cuidado contra vazamento foi aplicado na padronização das características: o normalizador (StandardScaler) foi ajustado apenas com os dados de treino de cada partição e então aplicado ao conjunto de teste. Ajustá-lo sobre todo o conjunto faria com que estatísticas do teste influenciassem o treino, o que também constitui vazamento de informação.

2.7 Combinação de Classificadores

Além dos classificadores individuais, avaliou-se uma combinação estática por votação majoritária. O ensemble foi construído a partir da combinação de cinco subconjuntos de características com quatro classificadores base, totalizando 20 membros distintos.

Os cinco subconjuntos de características foram:

- O conjunto completo (todas as 15 características).
- Características de frequência.
- Apenas as de tempo.
- Combinação dos parâmetros de Hjorth com as bandas de frequência.
- Subconjunto compacto com as características mais discriminativas.

Os quatro classificadores base foram: k-NN, árvore de decisão, SVM e Random Forest. O MLP foi excluído do ensemble por ser mais custoso computacionalmente, sem contribuir com diversidade proporcional ao custo.

Cada um dos 20 membros foi treinado e avaliado dentro do mesmo protocolo de validação por sujeito. Para cada época de teste, os 20 membros emitem um voto, e a classe final é definida pela maioria. A motivação por trás dessa abordagem é que membros diversos, que usam features e algoritmos diferentes, tendem a errar de formas diferentes. Quando os erros não são correlacionados, a votação cancela parte deles e a predição coletiva pode superar a de qualquer membro isolado.

2.8 Métricas

O desempenho foi avaliado por três medidas. A acurácia mede a proporção de épocas classificadas corretamente sobre o total. Embora intuitiva, ela é enganosa em conjuntos desbalanceados: um classificador que sempre previsse N2 (a classe majoritária) alcançaria cerca de 30% de acurácia sem aprender nada útil.

Por isso, utilizou-se também o F1-macro, que calcula o F1-score de cada classe separadamente e tira a média com peso igual entre as classes. Essa métrica penaliza o

modelo por ignorar as classes minoritárias (N1 e REM), sendo mais adequada para o desbalanceamento deste dataset.

Por fim, gerou-se a matriz de confusão de cada classificador, normalizada por linha (por classe verdadeira). Nessa representação, cada célula indica a porcentagem de épocas de um estágio verdadeiro que foram classificadas em cada estágio previsto; a diagonal principal corresponde à taxa de acerto por classe.

3. Resultados

3.1 Resultados de Classificadores Individuais

Esta tabela apresenta o desempenho dos cinco classificadores individuais:

Classificador	Acurácia	F1-macro
SVM (RBF)	74,5%	71,8%
Random Forest	72,9%	70,0%
MLP	71,7%	70,2%
k-NN	69,8%	67,6%
Árvore de Decisão	62,3%	59,8%

O SVM com kernel RBF obteve o melhor desempenho, seguido de perto pelo Random Forest e pelo MLP. A árvore de decisão isolada teve o pior resultado, comportamento esperado, já que uma única árvore tende a sofrer overfitting.

A matriz de confusão do SVM, o melhor classificador, evidencia o padrão de acertos e erros por estágio:

Previsto	Wake	N1	N2	N3	REM
Wake	86,2%	8,5%	3,0%	0,9%	1,3%
N1	14,8%	44,0%	22,9%	0,2%	18,0%
N2	2,4%	5,2%	78,4%	8,8%	5,2%
N3	0,7%	0,0%	18,1%	80,2%	1,0%
REM	2,5%	16,6%	10,4%	0,8%	69,8%

Wake, N2 e N3 foram os estágios mais bem classificados, enquanto o N1 foi o mais difícil, com apenas 44% de acerto.

3.2 Resultados do Ensemble

A combinação por votação majoritária dos 20 membros alcançou 71,0% de acurácia e 68,3% de F1-macro. Esse resultado ficou abaixo do melhor classificador individual, o SVM (74,5% / 71,8%).

Previsto	Wake	N1	N2	N3	REM
Wake	86,5%	7,8%	3,4%	0,9%	1,4%
N1	16,5%	42,9%	22,8%	0,6%	17,2%
N2	2,9%	5,2%	73,4%	12,8%	5,6%
N3	0,6%	0,0%	21,3%	77,3%	0,7%
REM	2,7%	21,2%	14,3%	1,5%	60,2%

O padrão de erros do ensemble é semelhante ao dos classificadores individuais, mas com desempenho inferior ao SVM nos estágios que este classificava melhor, sobretudo o REM (queda de cerca de 10 pontos) e N2.

4. Discussão e Análise

4.1 Pontos Fortes

Os estágios Wake, N2 e N3 foram classificados com boa taxa de acerto por todos os modelos. Esse resultado é consistente com a fisiologia do sono e com as características extraídas: o N3 é dominado por ondas delta de grande amplitude, capturadas pela potência relativa na banda delta. o N2 apresenta os fusos do sono na banda sigma, um marcador espectral específico; e a vigília tem atividade rápida (beta) e maior tônus muscular. Ou seja, esses estágios possuem assinaturas espectrais distintas que as features conseguem representar bem.

Entre os classificadores, o SVM com kernel RBF teve o melhor desempenho, o que é coerente com sua eficácia em problemas de dimensão moderada e com features bem projetadas.

4.2 Pontos Fracos

O estágio N1 foi o mais difícil de classificar, com taxa de acerto em torno de 44%. Isso tem explicação fisiológica: o N1 é um estágio de transição entre a vigília e o sono, curto e com EEG de características mistas, que compartilha propriedades tanto com o Wake quanto com o N2 e o REM. Por não possuir um marcador espectral único e estável, ele é confundido com os estágios vizinhos. Um problema bem conhecido na literatura, que afeta inclusive a concordância entre especialistas humanos.

As confusões observadas são fisiologicamente coerentes: o N1 se confunde com Wake e REM (todos com EEG de baixa amplitude e frequência mista), e o N3 se confunde com o N2 (estágios vizinhos no contínuo de profundidade do sono, ambos com atividade lenta). O desbalanceamento das classes, com N2 dominante e N1/REM minoritários, também contribui para a dificuldade nas classes raras.

4.3 Impacto da Combinação

Contrariando a expectativa de que a combinação melhoraria o desempenho, o ensemble por votação majoritária ficou abaixo do melhor classificador individual. Esse resultado, embora negativo, é informativo e tem causas bem definidas.

A votação majoritária atribui o mesmo peso a todos os membros, independente de sua qualidade. No ensemble construído, há membros fortes (como o SVM com todas as features) e membros fracos (como a árvore de decisão). Na votação simples, os membros fracos votam sistematicamente de forma errônea nos casos mais difíceis e acabam diluindo a contribuição dos membros fortes, puxando o resultado para baixo justamente nos estágios que o SVM classificava melhor.

Isso indica que a combinação de classificadores não garante melhora. O ganho depende da qualidade e da diversidade dos membros. Como caminhos para melhorar o ensemble, poderiam ser explorados a votação ponderada (atribuindo mais pesos aos membros de melhor desempenho), o *soft voting* (combinação das probabilidades em vez do voto rígido) e a seleção dos membros, removendo os mais fracos do conjunto.

5. Conclusão

Este trabalho avaliou um pipeline de classificação automática de estágios de sono a partir de um único canal de EEG, utilizando extração de características clássicas, cinco classificadores e uma combinação por votação majoritária, sob validação por sujeito.

Os classificadores individuais alcançaram o desempenho competitivo, com destaque para o SVM com kernel RBF (74,5% de acurácia e 71,8% de F1-macro). O estágio N1 mostrou-se o principal gargalo da classificação, por razões fisiológicas ligadas à sua natureza de transição. A combinação individual, evidenciando que a simples agregação de modelos diversos não garante melhora quando há grande disparidade de qualidade entre os membros.

6. Referências

- Khalighi, S., Sousa, T., Santos, J. M., & Nunes, U. (2016). ISRUC-Sleep: A comprehensive public dataset for sleep researchers. *Computer Methods and Programs in Biomedicine*, 124, 180-192.
- Hjorth, B. (1970), "EEG analysis based on time domain properties", *Electroencephalography and Clinical Neurophysiology*.

Welch, P. (1967). The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*, 15(2), 70-73.

Iber, C., Ancoli-Israel, S., Chesson, A. L., & Quan, S. F. (2007). The AASM Manual for the Scoring of Sleep and Associated Events: Rules, Terminology and Technical Specifications. American Academy of Sleep Medicine.

Rechtschaffen, A., & Kales, A. (1968). A Manual of Standardized Terminology, Techniques and Scoring System for Sleep Stages of Human Subjects. Public Health Service, U.S. Government Printing Office.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Gramfort, A., et al. (2013). MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7, 267.

Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357-362.

Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261-272.